



SYNTHÈSE DES TRAVAUX RÉALISÉS

Support de questions — Soutenance de Projet de Fin d'Année (PFA)

arhia

(Agent RH IA)

Assistant RH agentique pour l'Onboarding et l'Offboarding

Répondre aux questions RH (RAG documenté) et informer sur l'avancement d'un dossier — sans jamais exécuter d'action irréversible depuis la conversation.

Réalisé par	Encadrant
M. Komla Edem Wilfried Tsetse	M. Moulay Rachid Didi Alaoui

Dépôt GitHub privé, accessible sur demande : github.com/wekt2k04/arhia


1. Contexte et stratégie	p. 2
2. Architecture et stack technique	p. 2
3. Cœur du projet : sous-système IA	p. 3
4. Workflows métier	p. 3
5. Bilan vérifié + tableau récapitulatif	p. 3

1. Contexte et stratégie

- Agent conversationnel dédié à l'onboarding et à l'offboarding : politiques RH (RAG documenté) + suivi de dossier.
- Contrainte de conception assumée : **jamais** d'action irréversible déclenchée depuis la conversation.
- Une première itération a été ré-auditée en cours de stage et recentrée strictement sur l'onboarding/offboarding — **cette fiche décrit l'état actuel, fonctionnel de bout en bout.**


2. Architecture et stack technique

- **.NET 8**, architecture **hexagonale** à 4 couches : Domain → Core → Infrastructure → Api (une couche ne dépend que de celles listées en dessous).
- Frontend **Next.js 15** en **BFF** — le JWT n'est jamais exposé au navigateur (cookie `httpOnly`).
- **Auth & RBAC** : JWT + Identity, 3 rôles (`Employee/HR/QualityAdmin`), portée département vérifiée *avant* le rôle.
- Données : **SQL Server** (métier) + **Qdrant** (index vectoriel RAG). Temps réel : **SSE** (chat + notifications).
- Déploiement : **Docker Compose** (4 services) + Ollama natif sur l'hôte.




3. Cœur du projet : sous-système IA

- Pipeline **RAG en 4 phases obligatoires** : chunking structurel → embedding ONNX (768d) → stockage **Qdrant** (ANN/HNSW) → **reranking** cross-encodeur.
- **Router** (Ollama, phi4-mini:3.8b) classe l'intention ; sortie jamais utilisée telle quelle — retombe sur *hors périmètre* par défaut (**fail-safe, pas fail-open**).
- Le point le plus important du projet : **2 portes de sortie anticipée, en code**, avant tout appel au Generator — garde-fou anti-hallucination vérifiable et testé, pas une simple consigne de prompt.
- *Limite mesurée et assumée* : ~27% d'erreur de routage sur un jeu de 48 questions test, avec le modèle actuel sur matériel local sans GPU — documentée plutôt que masquée, sans impact sur le garde-fou (plan de déport de charge en §5).



4. Workflows métier

- **Onboarding** : fiche collaborateur → items résolus (Poste × Département × Contrat) contre le template approuvé → checklist persistée → clôture → archivage lecture seule.
- **Offboarding** : même mécanique générique (aucune distinction de code) — checklist dédiée dérivée d'un document réel (SMSI.ENR.10-2).
- **Circuit qualité des templates** : Rédacteur propose → Vérificateur → Approbateur — seul un template *Approved* peut instancier un dossier réel, contrainte vérifiée par le code.



5. Bilan vérifié

- **211 tests automatisés** (xUnit/Moq/FluentAssertions), **0 warning** au build. Pipeline RAG et chat vérifiés en HTTP réel de bout en bout (streaming inclus).
- Déploiement Docker Compose vérifié sur base fraîche : inscription → connexion → chat sourcé.
- *Suite prévue* : dès le **jeudi 27 août 2026** (retour en entreprise), déporter Router et Generator vers le **serveur Ollama de l'entreprise** (192.168.100.220:11434) — **phi4:14b** (même famille que le modèle actuel) à l'essai pour le Router, **gemma4:12b** (déjà identifié comme candidat mais écarté en local faute de GPU) pour le Generator — puis endpoints de lecture/liste, trois cas particuliers métier encore ouverts.

Composant	État
Architecture	Hexagonale, 4 couches — opérationnelle
Backend / Frontend	.NET 8 / Next.js 15 (BFF) — 211 tests verts, 0 warning
Sécurité	JWT + RBAC (3 rôles) + portée département vérifiée
RAG	4 phases (chunking / embedding / Qdrant / reranking) — vérifié en HTTP réel
Garde-fou anti-hallucination	2 portes de sortie anticipée en code — testé
Router	Classification 3 intentions — ~27% d'erreur (matériel local, isolée) ; déport serveur entreprise prévu 27/08
Workflows	Onboarding + Offboarding, mécanique générique — opérationnels de bout en bout
Déploiement	Docker Compose (4 services) + Ollama natif — vérifié sur base fraîche